

Universidade de São Paulo
Instituto de Ciências Matemáticas e de Computação – ICMC
Bacharelado em Ciência de Dados
Fundamentos em Ciências de Dados

Trabalho Prático

Análise Exploratória de Indicadores de Sono, Saúde e Estilo de Vida

Sleep Health and Lifestyle Dataset

Grupo:

Matheus Sanches Raimundo Mendonça

Docente responsável: Profa. Cibeles Russo

Monitora: Aline Pereira

Ano/Semestre: 1º semestre de 2026

São Carlos, SP
02 de Julho de 2026

Sumário

1	Introdução	2
2	Motivação	3
3	Descrição do problema e dos dados	4
3.1	Problema a ser estudado	4
3.2	Origem dos dados	4
3.3	Variáveis do conjunto de dados	5
4	Preparação dos dados	6
4.1	Carregamento e inspeção inicial	6
4.2	Tratamento de valores ausentes	6
4.3	Ajuste de variáveis	7
4.4	Resumo das etapas de pré-processamento	7
5	Análise exploratória dos dados	8
5.1	Distribuição da duração do sono	8
5.2	Distribuição da qualidade do sono	9
5.3	Qualidade do sono por categoria de IMC	10
5.4	Relação visual entre estresse e qualidade do sono	11
5.5	Duração do sono por ocupação	12
5.6	Distúrbios do sono e comparação entre grupos	13
5.7	Mapa de correlações	14
6	Resultados e limitações	16
6.1	Principais padrões observados	16
6.2	Limitações	18
7	Conclusão	19
	Referências Bibliográficas	20

Capítulo 1

Introdução

O sono é um componente essencial da rotina humana e está relacionado a diferentes aspectos do bem-estar físico e mental. Características como duração do sono, qualidade percebida, nível de estresse, atividade física, índice de massa corporal e indicadores cardiovasculares podem apresentar padrões relevantes quando observadas em conjunto. Nesse contexto, bases de dados que reúnem informações sobre hábitos diários e condições de saúde permitem realizar análises exploratórias voltadas à identificação de distribuições, comparações entre grupos e possíveis associações entre variáveis.

Este trabalho utiliza a base *Sleep Health and Lifestyle Dataset*, disponibilizada na plataforma Kaggle, com o objetivo de realizar uma análise exploratória de variáveis relacionadas ao sono, à saúde e ao estilo de vida. A análise busca observar padrões descritivos associados à duração do sono, à qualidade do sono e à presença ou ausência de distúrbios do sono registrados na base, considerando também variáveis como ocupação, nível de estresse, categoria de IMC, atividade física, frequência cardíaca e passos diários.

O estudo tem caráter exclusivamente exploratório. Portanto, não são realizados testes de hipótese, modelos preditivos ou procedimentos de inferência estatística. Dessa forma, os resultados apresentados ao longo do relatório devem ser interpretados com cautela e restritos à base analisada.

Assim, o relatório está organizado de modo a apresentar inicialmente a motivação e a descrição da base de dados, seguida das etapas de preparação e pré-processamento. Em seguida, são apresentadas as análises exploratórias por meio de tabelas e visualizações, buscando sintetizar os principais padrões observados e discutir as limitações do estudo.

Capítulo 2

Motivação

A escolha do tema foi motivada pela possibilidade de investigar, de forma descritiva, um assunto presente no cotidiano: a relação entre sono, saúde e estilo de vida. O sono está associado à rotina diária dos indivíduos e pode variar de acordo com diferentes características, como nível de estresse, ocupação, atividade física, índice de massa corporal e outros indicadores de saúde. Por isso, o tema permite uma análise intuitiva e de fácil interpretação, adequada para um estudo exploratório.

A base selecionada, *Sleep Health and Lifestyle Dataset*, apresenta variáveis numéricas e categóricas que possibilitam diferentes abordagens de visualização e comparação entre grupos. Entre as variáveis disponíveis, destacam-se duração do sono, qualidade do sono, nível de estresse, nível de atividade física, categoria de IMC, frequência cardíaca, passos diários, ocupação e presença de distúrbios do sono. Essa diversidade permite observar a distribuição das variáveis e levantar possíveis padrões dentro da base analisada.

Além disso, o conjunto de dados permite formular perguntas simples e interpretáveis, como: indivíduos com diferentes níveis de estresse apresentam distribuições distintas de qualidade do sono? A duração do sono varia visualmente entre ocupações? Há diferenças descritivas entre pessoas com e sem registro de distúrbio do sono? A categoria de IMC parece estar associada a diferentes padrões de qualidade do sono? Essas perguntas não buscam comprovar relações causais, mas sim orientar a exploração inicial dos dados.

Outro fator que motivou a escolha da base foi sua complexidade moderada. O conjunto de dados é suficientemente rico para permitir análises com tabelas, gráficos de barras, histogramas, boxplots, gráficos de dispersão e mapa de correlação, mas não exige técnicas avançadas de modelagem ou inferência estatística. Dessa forma, a base se mostra adequada aos objetivos do trabalho, que consistem em aplicar conceitos fundamentais de ciência de dados por meio da preparação, visualização e interpretação cuidadosa dos dados.

Capítulo 3

Descrição do problema e dos dados

3.1 Problema a ser estudado

O problema estudado consiste em realizar uma análise exploratória de variáveis relacionadas ao sono, à saúde e ao estilo de vida. O objetivo geral é observar distribuições, comparar grupos e identificar possíveis padrões na base analisada.

As principais perguntas exploratórias são:

- a) Como se distribuem a duração e a qualidade do sono na base analisada?
- b) A qualidade do sono apresenta diferenças visuais entre categorias de IMC?
- c) O nível de estresse apresenta algum padrão visual em relação à qualidade do sono?
- d) A duração do sono varia de forma descritiva entre diferentes ocupações?
- e) Pessoas com e sem distúrbio do sono apresentam diferenças descritivas em variáveis como frequência cardíaca, passos diários e estresse?

3.2 Origem dos dados

O conjunto de dados utilizado é o *Sleep Health and Lifestyle Dataset*, disponível publicamente na plataforma Kaggle. A base reúne informações relacionadas a padrões de sono, hábitos de vida e indicadores de saúde. Entre as variáveis disponíveis, destacam-se: gênero, idade, ocupação, duração do sono, qualidade do sono, nível de atividade física, nível de estresse, categoria de IMC, pressão arterial, frequência cardíaca, passos diários e presença de distúrbios do sono.

O acesso à base foi realizado por meio do endereço:

<https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>

A análise computacional foi desenvolvida em um notebook do Google Colab, e os arquivos do projeto serão disponibilizados em um repositório no GitHub:

- **Notebook:** <https://colab.research.google.com/drive/1PjUAoev2Ec1W2VizYmPZm4V-bPpU-1Zo?usp=sharing>
- **Repositório:** <https://github.com/mathsrn/fcd-sleep-health-lifestyle-e-da>

3.3 Variáveis do conjunto de dados

A Tabela 3.1 apresenta uma descrição inicial das variáveis consideradas no estudo. A classificação entre variáveis numéricas e categóricas é utilizada apenas para orientar as etapas de limpeza, resumo e visualização.

Tabela 3.1: Descrição das variáveis da base de dados.

Variável	Tipo	Descrição
<i>Person ID</i>	Identificação	Identificador do indivíduo na base.
<i>Gender</i>	Categórica	Gênero informado no conjunto de dados.
<i>Age</i>	Numérica	Idade do indivíduo.
<i>Occupation</i>	Categórica	Ocupação ou profissão registrada.
<i>Sleep Duration</i>	Numérica	Duração do sono, em horas.
<i>Quality of Sleep</i>	Numérica discreta	Indicador de qualidade do sono.
<i>Physical Activity Level</i>	Numérica	Nível de atividade física.
<i>Stress Level</i>	Numérica discreta	Indicador de nível de estresse.
<i>BMI Category</i>	Categórica	Categoria de índice de massa corporal.
<i>Blood Pressure</i>	Textual	Pressão arterial registrada no formato sistólica/diastólica.
<i>Heart Rate</i>	Numérica	Frequência cardíaca.
<i>Daily Steps</i>	Numérica	Quantidade de passos diários.
<i>Sleep Disorder</i>	Categórica	Registro de distúrbio do sono, quando informado na base.

Capítulo 4

Preparação dos dados

A preparação dos dados foi realizada no Google Colab, utilizando a linguagem Python e bibliotecas voltadas à análise de dados, como *pandas*, *numpy*, *matplotlib* e *seaborn*. O objetivo desta etapa foi organizar a base para permitir análises descritivas e visualizações coerentes.

4.1 Carregamento e inspeção inicial

Inicialmente, o arquivo CSV foi carregado no notebook. Em seguida, foram verificados o número de linhas e colunas, os nomes das variáveis, os tipos de dados e as primeiras observações. Essa inspeção foi importante para compreender a estrutura da base antes da construção dos gráficos.

Também foi feita a verificação de valores ausentes e de possíveis registros duplicados. Caso a execução do notebook identifique duplicidades, estas devem ser removidas para evitar que uma mesma observação influencie indevidamente as análises descritivas.

4.2 Tratamento de valores ausentes

Durante a inspeção inicial da base, verificou-se que a única coluna com valores ausentes era *Sleep Disorder*. Essa variável registra a presença de distúrbios do sono, como insônia ou apneia do sono. No entanto, os valores ausentes nessa coluna indicavam indivíduos sem distúrbio do sono registrado.

Dessa forma, os valores ausentes da coluna *Sleep Disorder* foram preenchidos com a categoria *No Sleep Disorder*. Essa etapa foi realizada para padronizar a informação e permitir a comparação entre indivíduos com e sem registro de distúrbio do sono. É importante destacar que essa decisão representa apenas uma organização dos dados para fins de análise exploratória, não devendo ser interpretada como diagnóstico clínico.

As demais colunas da base não apresentaram valores ausentes. Assim, não foi necessário realizar remoção de linhas ou preenchimento de dados em outras variáveis.

4.3 Ajuste de variáveis

A variável *Blood Pressure* está registrada em formato textual, como uma combinação entre pressão sistólica e diastólica. Para facilitar a análise, essa coluna foi separada em duas variáveis numéricas: *Systolic BP* e *Diastolic BP*. Essa transformação permite observar separadamente os dois componentes da pressão arterial.

Também foram padronizados nomes de colunas, quando necessário, e revisadas categorias textuais para evitar problemas causados por espaços extras ou variações de escrita.

4.4 Resumo das etapas de pré-processamento

As principais etapas de preparação foram:

- carregamento do arquivo CSV no Google Colab;
- inspeção dos tipos das variáveis;
- identificação de valores ausentes;
- tratamento da coluna *Sleep Disorder*;
- verificação e remoção de duplicidades, caso existam;
- separação da variável *Blood Pressure* em pressão sistólica e diastólica;
- exportação de uma versão tratada da base para uso no relatório e no repositório.

Capítulo 5

Análise exploratória dos dados

A análise exploratória foi organizada a partir de tabelas descritivas e gráficos. O objetivo foi observar padrões gerais da base, comparar grupos e levantar possíveis associações visuais entre variáveis. Não foram realizados testes de hipótese, intervalos de confiança ou modelos estatísticos inferenciais.

5.1 Distribuição da duração do sono

A Figura 5.1 apresenta a distribuição da variável *Sleep Duration*. Esse gráfico permite observar a concentração dos valores de duração do sono e identificar se há assimetrias, valores extremos ou faixas mais frequentes na base analisada.




Figura 5.1: Distribuição da duração do sono na base analisada.

A partir do histograma, deve-se descrever apenas o padrão observado na amostra, evitando afirmações gerais sobre a população. Um exemplo de interpretação adequada é: “na base analisada, a duração do sono parece se concentrar em determinada faixa de horas, com menor frequência de observações nas extremidades da distribuição”.

5.2 Distribuição da qualidade do sono

A qualidade do sono foi analisada inicialmente por meio de medidas descritivas e visualizações de frequência. Essa variável permite observar a distribuição dos níveis de qualidade registrados na base.




Figura 5.2: Frequência dos níveis de qualidade do sono.

Esse gráfico permite verificar quais níveis de qualidade do sono aparecem com maior frequência. Como se trata de uma análise exploratória, a interpretação deve se limitar à descrição da base utilizada.

5.3 Qualidade do sono por categoria de IMC

Para comparar a qualidade do sono entre grupos, foi utilizado um boxplot considerando as categorias de IMC. Antes da Figura 5.3, é importante destacar que o boxplot permite observar mediana, dispersão e possíveis valores extremos em cada grupo, mas não comprova diferença estatística entre as categorias.




Figura 5.3: Qualidade do sono por categoria de IMC.

A interpretação desse gráfico deve ser feita em termos exploratórios. Por exemplo, caso as distribuições estejam deslocadas entre categorias, pode-se afirmar que “os boxplots sugerem diferenças visuais na distribuição da qualidade do sono entre algumas categorias de IMC”. Não se deve afirmar que a categoria de IMC causa mudanças na qualidade do sono.

5.4 Relação visual entre estresse e qualidade do sono

A Figura 5.4 apresenta um gráfico de dispersão entre *Stress Level* e *Quality of Sleep*. Esse tipo de gráfico auxilia na observação de possíveis associações visuais entre duas variáveis numéricas ou ordinais.




Figura 5.4: Dispersão entre nível de estresse e qualidade do sono.

Caso seja observada uma tendência visual, a redação deve permanecer cautelosa. Uma forma adequada de descrever o resultado é: “na base analisada, níveis mais altos de estresse parecem estar associados visualmente a menores valores de qualidade do sono”. Essa formulação evita afirmar causalidade.

5.5 Duração do sono por ocupação

A ocupação dos indivíduos foi analisada como uma variável categórica. Para evitar gráficos excessivamente poluídos, recomenda-se ordenar as ocupações por duração média ou mediana do sono e limitar a interpretação aos grupos com quantidade suficiente de observações.




Figura 5.5: Duração do sono por ocupação.

Esse gráfico permite observar se algumas ocupações apresentam maior ou menor dispersão na duração do sono. Contudo, ocupações com poucas observações devem ser interpretadas com maior cautela, pois podem produzir padrões instáveis.

5.6 Distúrbios do sono e comparação entre grupos

A variável *Sleep Disorder* foi analisada para observar a distribuição dos registros de distúrbio do sono na base. A Figura 5.6 apresenta a frequência de cada categoria.




Figura 5.6: Frequência das categorias de distúrbio do sono.

Também foram realizadas comparações descritivas entre grupos com e sem distúrbio do sono. A Tabela 5.1 deve ser preenchida com os valores obtidos no notebook após a execução da análise.

Tabela 5.1: Resumo descritivo por categoria de distúrbio do sono.

Categoria	n	Sono médio	Estresse médio	Passos médios
No Sleep Disorder	—	—	—	—
Insomnia	—	—	—	—
Sleep Apnea	—	—	—	—

Na redação final, essa tabela pode ser descrita em termos como: “observa-se que determinados grupos apresentam médias distintas na base analisada”. Não se deve afirmar que a presença de distúrbio do sono é consequência direta de uma variável específica.

5.7 Mapa de correlações

Como etapa complementar, foi construído um mapa de correlações entre variáveis numéricas. A Figura 5.7 permite observar pares de variáveis com maior associação linear na base analisada.




Figura 5.7: Mapa de correlações entre variáveis numéricas.

A correlação deve ser interpretada apenas como uma medida descritiva de associação linear. Valores altos ou baixos de correlação não indicam, por si só, causalidade entre variáveis. Além disso, relações não lineares podem não ser bem representadas por essa medida.

Capítulo 6

Resultados e limitações

6.1 Principais padrões observados

A análise exploratória realizada no notebook permitiu identificar alguns padrões descritivos na base *Sleep Health and Lifestyle Dataset*. Inicialmente, observou-se que a base possui 374 registros e 13 variáveis originais. Após o pré-processamento, foram criadas também as variáveis de pressão sistólica e pressão diastólica, obtidas a partir da separação da coluna *Blood Pressure*. Não foram identificadas linhas duplicadas, e a única variável com valores ausentes foi *Sleep Disorder*, cujos valores faltantes foram preenchidos com a categoria *Nenhum*, indicando ausência de distúrbio do sono registrado.

Em relação à duração do sono, os valores variaram entre 5,8 e 8,5 horas, com média aproximadamente igual a 7,13 horas e mediana de 7,20 horas. O histograma indica que a maior parte dos registros está concentrada em uma faixa intermediária de duração do sono, embora existam variações entre os indivíduos presentes na base. Essa análise descreve apenas a distribuição observada no conjunto de dados, sem permitir generalizações para a população.

Quanto à qualidade do sono, os valores registrados variaram de 4 a 9. O gráfico de barras mostrou maior frequência nos níveis 6 e 8, enquanto os níveis 4 e 5 apareceram com menor frequência. Esse resultado sugere que, dentro da base analisada, a qualidade do sono tende a se concentrar em valores intermediários e altos, mas com presença de indivíduos que apresentam menores valores de qualidade do sono.

Na comparação entre qualidade do sono e categoria de IMC, os boxplots sugerem diferenças visuais entre os grupos. A categoria *Normal* apresentou mediana igual a 8 e média de aproximadamente 7,64. A categoria *Overweight* (Sobrepeso) apresentou mediana igual a 6 e média de aproximadamente 6,90. Já a categoria *Obese* (Obeso) apresentou mediana igual a 7 e média de aproximadamente 6,40. No entanto, essa última categoria possui apenas 10 registros, o que limita a interpretação dos resultados. Assim, os pa-

drões observados devem ser entendidos apenas como diferenças descritivas dentro da base analisada.

A relação entre nível de estresse e qualidade do sono também apresentou um padrão visual relevante. Nos níveis mais baixos de estresse, foram observados valores maiores de qualidade do sono. Por exemplo, para o nível de estresse 3, a mediana da qualidade do sono foi 9, enquanto para o nível de estresse 8, a mediana foi 6. Esse comportamento sugere uma possível associação visual entre maiores níveis de estresse e menores valores de qualidade do sono na base analisada. Entretanto, como não foram aplicados testes estatísticos ou modelos causais, não é possível afirmar que o estresse provoque redução na qualidade do sono.

A comparação da duração do sono por ocupação também indicou diferenças descritivas entre grupos. Considerando apenas ocupações com pelo menos cinco registros, observou-se que *Engineer* (Engenheiro) apresentou a maior mediana de duração do sono, aproximadamente 8,30 horas. Em seguida, aparecem ocupações como *Doctor* (Médico), *Lawyer* (Advogado) e *Accountant* (Contador). Por outro lado, *Salesperson* (Vendedor), *Nurse* (Enfermeiro) e *Teacher* (Professor) apresentaram medianas menores. Essas diferenças podem estar relacionadas às características dos indivíduos presentes na base, mas não devem ser interpretadas como efeito direto da ocupação sobre a duração do sono.

Na análise dos distúrbios do sono, observou-se que 219 indivíduos não possuíam distúrbio registrado, enquanto 78 apresentavam *Sleep Apnea* (Apnéia do sono) e 77 apresentavam *Insomnia* (Insônia). Ao cruzar essa variável com a categoria de IMC, foi possível observar que, na categoria Normal, a maioria dos indivíduos não possuía distúrbio registrado. Já na categoria *Overweight*, houve maior presença de registros de insônia e apnéia do sono. Na categoria *Obese*, todos os registros apresentaram algum distúrbio do sono, mas essa categoria possui apenas 10 observações, o que exige cautela na interpretação.

A comparação entre indivíduos com e sem registro de distúrbio do sono também apresentou diferenças descritivas. O grupo sem distúrbio registrado apresentou maior média de duração do sono, aproximadamente 7,36 horas, enquanto o grupo com distúrbio registrado apresentou média de aproximadamente 6,81 horas. Em relação à qualidade do sono, o grupo sem distúrbio registrado apresentou média de 7,63, enquanto o grupo com distúrbio registrado apresentou média de 6,87. Além disso, o grupo com distúrbio registrado apresentou maiores valores médios de nível de estresse, frequência cardíaca e pressão arterial sistólica e diastólica. Esses resultados sugerem diferenças entre os perfis dos grupos na base analisada, mas não permitem estabelecer relações causais.

De modo geral, os resultados indicam possíveis padrões entre variáveis relacionadas ao sono, estilo de vida e indicadores de saúde. As visualizações e tabelas permitiram observar diferenças entre grupos e possíveis associações visuais, principalmente envolvendo qualidade do sono, nível de estresse, categoria de IMC, ocupação e presença de distúrbios

do sono. No entanto, todas as interpretações devem ser entendidas como exploratórias e restritas ao conjunto de dados utilizado.

6.2 Limitações

Apesar de a base permitir diferentes análises exploratórias, algumas limitações devem ser consideradas. A primeira delas é o tamanho da base, composta por 374 registros. Embora esse número seja suficiente para a construção de tabelas e gráficos descritivos, ele não garante representatividade da população geral.

Outra limitação está relacionada ao desbalanceamento entre algumas categorias. Por exemplo, a categoria *Obese* (Obeso) possui apenas 10 registros, enquanto a categoria Normal possui 216 registros e a categoria *Overweight* (Sobrepeso) possui 148 registros. De forma semelhante, algumas ocupações possuem poucos indivíduos registrados. Por esse motivo, no boxplot de duração do sono por ocupação, foram consideradas apenas ocupações com pelo menos cinco registros. Essa decisão melhora a visualização, mas também reduz a abrangência da comparação entre todas as ocupações presentes na base.

Também é importante destacar que a análise realizada é exclusivamente exploratória. Não foram aplicados testes de hipótese, intervalos de confiança, modelos preditivos ou técnicas de inferência estatística. Dessa forma, os resultados não devem ser interpretados como comprovação de relações entre variáveis. As diferenças observadas nos gráficos e tabelas indicam apenas padrões descritivos dentro da base analisada.

Além disso, o tratamento dos valores ausentes na variável *Sleep Disorder* foi feito por meio do preenchimento com a categoria *Nenhum*. Essa escolha foi adotada para organizar a base e permitir a comparação entre indivíduos com e sem distúrbio do sono registrado. No entanto, essa etapa não deve ser interpretada como diagnóstico clínico, mas apenas como uma padronização dos dados para fins de análise.

Outra limitação é que a base não contém necessariamente todas as variáveis que poderiam influenciar padrões de sono, como hábitos alimentares, consumo de cafeína, uso de medicamentos, rotina de trabalho, condições psicológicas ou histórico médico detalhado. Portanto, possíveis fatores relevantes podem não estar representados no conjunto de dados.

Por fim, os resultados obtidos devem ser interpretados com cautela e não podem ser generalizados para toda a população. O estudo fornece apenas um panorama inicial da base analisada e pode servir como ponto de partida para investigações futuras mais aprofundadas.

Capítulo 7

Conclusão

Este trabalho realizou uma análise exploratória da base *Sleep Health and Lifestyle Dataset*, com foco em variáveis relacionadas à duração do sono, qualidade do sono, hábitos de vida e indicadores de saúde. Foram realizadas etapas de preparação da base, tratamento de valores ausentes, verificação de duplicidades, transformação da variável de pressão arterial e construção de tabelas e gráficos descritivos.

As visualizações permitiram observar distribuições, comparar grupos e levantar possíveis associações visuais entre variáveis. Entre os gráficos utilizados, destacam-se histogramas, gráficos de barras, boxplots, gráficos de dispersão e mapa de correlações. Esses recursos permitiram organizar a análise de forma compatível com uma abordagem exploratória de dados.

De modo geral, os resultados devem ser entendidos como padrões observados na base analisada, e não como conclusões definitivas sobre a população. Para aprofundar o estudo, análises futuras poderiam considerar bases maiores, informações adicionais sobre hábitos de sono e métodos estatísticos apropriados, desde que compatíveis com os objetivos da investigação.

Referências Bibliográficas

- [1] Laksika Tharmalingam. *Sleep Health and Lifestyle Dataset*. Kaggle. Disponível em: <https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>. Acesso em: 02 de Junho de 2026.
- [2] McKinney, Wes. *pandas: a foundational Python library for data analysis and statistics*. Python for High Performance and Scientific Computing, 2011.
- [3] Hunter, John D. *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering, v. 9, n. 3, p. 90–95, 2007.
- [4] Waskom, Michael L. *seaborn: statistical data visualization*. Journal of Open Source Software, v. 6, n. 60, p. 3021, 2021.